

Relatório sobre a atividade “14 - Prática: Redes Neurais Convolucionais 1 (Deep Learning) (II)”

Lucas Gabriel Arenhardt

1. Introdução

Neste módulo, foram apresentadas as Redes Neurais Convolucionais, destacando a sua importância ao lidar com imagens. Os diversos conceitos aprendidos durante as aulas estão apresentados a seguir.

2. Conceitos

2.1. Pixels

São os pequenos pontos que formam uma imagem. Cada pixel possui 3 canais que representam as cores no formato RGB. Uma imagem em escala de cinza apresenta os mesmos valores para os canais RGB em um pixel, logo possui um tamanho reduzido em comparação a uma imagem colorida.

2.2. Rede Neural Convolucional (CNN)

Uma Rede Neural Convolucional (CNN) aplica um pré-processamento nas imagens por meio de operações de convolução, que utilizam filtros para extrair automaticamente as características mais relevantes, como bordas e texturas. Esse processo reduz a complexidade da imagem ao diminuir a quantidade de pixels, mas mantém informações essenciais. Após a extração das características, a CNN utiliza camadas densas para classificar ou fazer previsões, transformando assim os dados em uma representação mais simples e focada, que é usada na tarefa final, como reconhecimento de objetos ou classificação de imagens.

A seguir estão explicadas as etapas de uma CNN:

2.2.1. Operador de Convolução

O operador de convolução é uma operação que aplica um filtro sobre uma imagem para extrair características como bordas e texturas. O filtro, uma pequena matriz de pesos, é multiplicado pelos valores dos pixels da imagem em diferentes posições, e os resultados são somados para formar um novo valor no mapa de características. A função de ativação aplicada aos mapas de características é a ReLU.

Esse processo é repetido ao longo da imagem, permitindo que a rede destaque informações relevantes.

Input		Kernel		Output																	
<table border="1" style="border-collapse: collapse;"> <tr><td>0</td><td>1</td><td>2</td></tr> <tr><td>3</td><td>4</td><td>5</td></tr> <tr><td>6</td><td>7</td><td>8</td></tr> </table>	0	1	2	3	4	5	6	7	8	*	<table border="1" style="border-collapse: collapse;"> <tr><td>0</td><td>1</td></tr> <tr><td>2</td><td>3</td></tr> </table>	0	1	2	3	=	<table border="1" style="border-collapse: collapse;"> <tr><td>19</td><td>25</td></tr> <tr><td>37</td><td>43</td></tr> </table>	19	25	37	43
0	1	2																			
3	4	5																			
6	7	8																			
0	1																				
2	3																				
19	25																				
37	43																				

Imagem 1 - Exemplo da aplicação de um operador de convolução.

2.2.2. Max Pooling

É uma técnica usada em Redes Neurais Convolucionais para reduzir a dimensionalidade dos mapas de características, mantendo as informações mais importantes. Ele funciona ao aplicar uma janela de tamanho fixo, como 2x2, sobre o mapa de características e selecionando o valor máximo dentro de cada janela para representar essa região na saída.




Imagem 2 - Exemplo da aplicação do Max Pooling.

2.2.3. Flattening

É a operação que converte a matriz multidimensional resultante das camadas convolucionais e de pooling em um vetor unidimensional.

2.2.4. Rede Neural Densa

Após o processo de Flattening, que transforma a saída das camadas convolucionais e de pooling em um vetor unidimensional, cada valor desse vetor é enviado para a camada de entrada de uma Rede Neural Densa. Nessa etapa, a Rede

Neural Densa é responsável por processar e interpretar esses valores, realizando a tarefa final de previsão ou classificação com base nas características extraídas e representadas no vetor.

3. Conclusão

A prática com Redes Neurais Convolucionais revelou a eficácia dessas redes em lidar com imagens, extraindo e processando características importantes para tarefas de reconhecimento e classificação. A operação de convolução permite a extração de características importantes, enquanto o Max Pooling reduz a dimensionalidade dos dados mantendo informações essenciais. O processo de Flattening converte a saída das camadas convolucionais em um vetor unidimensional, que é então interpretado por uma Rede Neural Densa para gerar previsões ou classificações. Esses conceitos e técnicas são fundamentais para o desenvolvimento de modelos de aprendizado profundo robustos e eficientes na análise de imagens.