

Relatório sobre a atividade “15 - Prática: Redes Neurais Convolucionais 2 (Deep Learning) (II)”

Lucas Gabriel Arenhardt

1. Introdução

Neste módulo, foram apresentadas as Redes Neurais Convolucionais, muito utilizadas para o processamento de imagens e também de linguagens. Os conceitos aprendidos nas aulas estão representados a seguir.

2. Conceitos

2.1. Convolução

A convolução é uma operação matemática fundamental na área de Redes Neurais Convolucionais. É uma maneira de combinar duas funções para produzir uma terceira função. Sua aplicação em imagens, por exemplo, permite extrair características tais como bordas e objetos. A convolução, portanto, pode ser entendida como um modificador.

Os componentes-chave da operação de convolução são os seguintes:

2.1.1. Kernel ou Filtro

Uma pequena matriz de pesos que é aplicada à entrada, geralmente de tamanhos 3x3, 5x5 ou 7x7. Esse kernel “desliza” sobre a entrada, realizando as operações de multiplicação e soma.




Imagem 1 - Aplicação de um Kernel à entrada.

2.2.2. Stride

O stride é a quantidade de pixels que o filtro se desloca por loop. Vale destacar que quanto maior o stride, mais a imagem será reduzida.

2.2.3. Padding

Operação que adiciona zeros ao redor da borda da imagem de entrada. Isso é feito para manter o tamanho original da imagem, ou modificá-lo da forma desejada.

Image

0	0	0	0	0	0	0
0						0
0						0
0						0
0						0
0						0
0	0	0	0	0	0	0

Imagem 2 - Exemplo de Padding.

2.2.4. Mapa de características

É o resultado da aplicação dos filtros na imagem de entrada. Cada filtro gera um mapa de características diferente, que destaca certas informações da imagem recebida.

2.2. Redes Neurais Convolucionais (CNNs)

Após compreender o conceito de convolução, podemos aplicá-lo às Redes Neurais Convolucionais (CNNs). Uma CNN é composta por várias camadas, sendo as camadas de convolução responsáveis por extrair características relevantes da entrada, que frequentemente são imagens. Nessas camadas, filtros são aplicados à imagem, permitindo que a rede detecte padrões como bordas, texturas e formas em diferentes níveis de complexidade.

As características extraídas pelas camadas convolucionais são, então, passadas para as camadas densas. Nestas camadas, as informações são processadas e combinadas para realizar a tarefa final, como classificação, detecção de objetos ou segmentação. Assim, as camadas convolucionais funcionam como extratoras de características, enquanto as camadas densas atuam na interpretação e tomada de decisão com base nessas características extraídas.

2.3. Estrutura de uma CNN

Uma CNN geralmente é composta da seguinte forma:




Imagem 3 - Estrutura de uma Rede Neural Convolucional.

2.3.1. Camadas de Convolução

Como dito anteriormente, as camadas de convolução são responsáveis pela extração das informações, formando os mapas de características. Entre as operações de convolução podem ser aplicadas as funções de normalização, sendo a mais comum a função Batch Normalization. Em alguns casos, a normalização ajuda a acelerar o treinamento. Além disso, atua como uma forma de regularização, reduzindo o risco de overfitting.

2.3.2. Camadas de Pooling

As camadas de pooling têm a função de reduzir o tamanho dos mapas de características gerados pelas camadas de convolução. Essa redução é feita de forma a preservar as informações mais importantes, o que ajuda a reduzir a complexidade computacional do modelo.

Entre os tipos de pooling, os mais utilizados são o Max Pooling e o Average Pooling. No Max Pooling, o valor máximo dentro de uma região especificada é

selecionado, enquanto no Average Pooling, é calculada a média dos valores dentro dessa região.




Imagem 4 - Operação de Max Pooling.




Imagem 5 - Operação de Average Pooling.

2.3.3. Flattening

A operação de Flattening consiste em converter os valores multidimensionais gerados pelas camadas anteriores em um vetor unidimensional. Esse vetor é, então, utilizado como entrada para a primeira camada densa da rede. Essa transformação é necessária porque as camadas densas requerem uma entrada unidimensional para funcionar corretamente.

Vale destacar que, em alguns casos, o Flattening pode ser substituído pelo Global Max Pooling, operação onde cada mapa de características é reduzido a um único valor, sendo esse o valor máximo em toda a extensão do mapa. Isso resulta em um vetor onde cada elemento representa a característica mais forte em cada canal.

A principal diferença entre as duas operações é que, enquanto o Flattening preserva todas as características aprendidas, o Global Max Pooling captura apenas as

características mais destacadas em cada canal, o que pode resultar na perda de informações.

A escolha entre Flattening e Global Max Pooling deve considerar o equilíbrio entre a necessidade de detalhes na representação dos dados e a simplicidade desejada no modelo.




Imagem 5 - Representação da operação de Flattening.




Imagem 6 - Representação da operação de Global Max Pooling.

2.3.4. Camadas Densas

São camadas onde todos os neurônios de uma camada estão completamente conectados com os neurônios da camada seguinte. Elas são responsáveis por processar as informações extraídas e realizar a tarefa final, conforme requerido pelo tipo do modelo.

3. Conclusão

Neste módulo, foram explorados os principais conceitos e componentes das Redes Neurais Convolucionais (CNNs), amplamente utilizadas para o processamento de imagens e outras tarefas que envolvem dados espaciais. A operação de convolução e seus elementos, como o kernel, stride e padding, foram discutidos, destacando como eles ajudam na extração de características importantes das imagens.

A estrutura de uma CNN foi analisada, incluindo as camadas de convolução, pooling, flattening e densas, e como cada uma dessas camadas desempenha um papel essencial no funcionamento da rede, desde a extração de características até a interpretação e a tomada de decisão final.

Em resumo, compreender as CNNs é crucial para o desenvolvimento de soluções eficazes em Deep Learning, especialmente para tarefas relacionadas ao processamento de imagens. A escolha e configuração adequadas das camadas de uma CNN são fundamentais para o sucesso do modelo, e entender esses conceitos é essencial para o ajuste dos parâmetros.