

Relatório sobre a atividade “17 - Vídeo: Como Estamos Ensinando os Computadores a Compreender Fotos (III)”

Lucas Gabriel Arenhardt

Neste módulo é apresentado um vídeo onde a cientista de computação chinesa Fei-Fei Li fala sobre visão computacional e inteligência artificial.

Vivemos em um mundo altamente tecnológico, onde fotos e imagens são divulgadas constantemente na internet. Os smartphones possuem câmeras cada vez melhores, com cada vez mais megapixels. Tudo isso permite a nós, humanos, enxergarmos com mais clareza e percebermos mais os detalhes nas fotos. Os computadores, porém, não conseguem realizar a mesma ação. Fei-Fei Li exemplifica isso ao dizer que carros autônomos foram criados, porém não conseguem diferenciar uma sacola de papel amassada de uma pedra que deve ser desviada, ou então câmeras de segurança que estão em todos os lugares, mas não conseguem alertar quando há alguém se afogando, por exemplo. Assim sendo, mesmo as melhores máquinas do mundo ainda são cegas. Nesse contexto, surge a visão computacional.

No início, os algoritmos de visão computacional não funcionavam da forma esperada. Fei-Fei Li diz que uma das primeiras ideias foi modelar os objetos de forma matemática para o computador entender. O que acontecia, porém, era que caso a forma estivesse ligeiramente alterada, a máquina não era mais capaz de compreender. Sendo assim, após observar o comportamento de uma criança ao enxergar, a cientista de computação teve uma ideia: ninguém ensina uma criança a ver, elas aprendem por meio da própria experiência, ao ver milhões e milhões de imagens. Será que essa mesma lógica funcionaria com uma máquina?

Para testar isso, Fei-Fei Li precisava de muitas imagens. Assim, em 2007, foi lançado o projeto ImageNet - um banco de dados que contém mais de 14 milhões de imagens atualmente, todas rotuladas. Tendo o conjunto de dados, era necessário um algoritmo de aprendizado de máquina que fosse capaz de processar tudo isso da melhor maneira possível. A classe que mais se encaixou foi a de Redes Neurais Convolucionais (CNNs). O modelo criado foi enorme, com mais de 15 bilhões de conexões entre os neurônios. Segundo Fei-Fei Li, a CNN teve um desempenho ótimo, de forma que ninguém esperava o resultado entregue. Agora a máquina era capaz de dizer os elementos presentes em uma foto.




Imagem 1 - Exemplo de um algoritmo rotulando os elementos presentes em uma foto.

O desenvolvimento da visão computacional, porém, não parou por aí. A cientista de computação foi além e permitiu às máquinas formularem frases sobre os elementos presentes em uma imagem. Foi desenvolvido um modelo que combina fragmentos visuais com palavras e ideias em frases.



Imagem 2 - Frase gerada sobre a imagem pelo algoritmo de visão computacional.

Mesmo com o modelo possuindo seus defeitos e não sendo 100% eficaz, é um avanço muito grande para a área. Até agora as máquinas são capazes de dizer os elementos presentes em uma foto e também formar pequenas frases sobre a mesma. O próximo passo, segundo Fei-Fei Li é ensiná-las a interpretar o contexto dos elementos presentes.

A cientista finaliza dizendo que, primeiro ensinamos as máquinas a ver, em seguida, elas nos ajudam a enxergar melhor.