

Relatório sobre a atividade “24 - Prática: Sistemas de Recomendação (III)”

Lucas Gabriel Arenhardt

1. Introdução

O foco deste módulo foi trabalhar com sistemas de recomendações através de duas diferentes abordagens. Ambos os métodos utilizaram a biblioteca Pandas para realizar a manipulação dos dados.

2. “How Build A Movie Recommendation System Using Python | Python Tutorial For Beginners | Simplilearn”

Neste vídeo, o sistema de recomendação foi construído utilizando as bibliotecas sklearn e nltk. Primeiramente, fez-se a manipulação dos dados para manter apenas aquilo que era importante para a análise. Nesse processo, algumas colunas foram descartadas e os dados foram transformados em array, onde todas as letras são minúsculas e os nomes definidos por mais de duas palavras não possuem espaço entre elas.

	movie_id		title	tags
0	19995		Avatar	in the 22nd century, a paraplegic marine is di...
1	285	Pirates of the Caribbean: At World's End		captain barbossa, long believed to be dead, ha...
2	206647		Spectre	a cryptic message from bond's past sends him o...
3	49026	The Dark Knight Rises		following the death of district attorney harve...
4	49529		John Carter	john carter is a war-weary, former military ca...
...	...		...	...
4803	9367		El Mariachi	el mariachi just wants to play his guitar and ...
4804	72766		Newlyweds	a newlywed couple's honeymoon is upended by th...
4805	231617	Signed, Sealed, Delivered		"signed, sealed, delivered" introduces a dedic...
4806	126186		Shanghai Calling	when ambitious new york attorney sam is sent t...
4807	25975		My Date with Drew	ever since the second grade when he first saw ...

4805 rows × 3 columns

Imagem 1 - Dados após a manipulação.

Em seguida, da biblioteca sklearn importou-se a função CountVectorizer() e esta foi aplicada nos dados da coluna ‘tags’. Essa função é usada para transformar uma coleção de documentos de texto em uma matriz de contagem de tokens (palavras). Basicamente, ela converte o texto em uma representação numérica, onde cada coluna representa uma palavra única e cada linha representa um documento. O valor em cada célula da matriz é a contagem de vezes que a palavra aparece no documento correspondente.

Após essa operação, também foi necessário importar a função PorterStemmer() da biblioteca nltk e esta foi utilizada no resultado obtido pela etapa anterior. O PorterStemmer() é responsável por

transformar as palavras em sua forma base ou raiz. Por exemplo, a palavra “running” é transformada para “run”.

Por fim, também da biblioteca sklearn foi importada a função cosine_similarity(), que mede a distância entre dois vetores. Ao aplicar essa função nos vetores formados pelo conjunto de dados da coluna ‘tags’, tem-se o valor da similaridade entre os filmes. Visto isso, é criada uma função que recebe como parâmetro o título de um filme, verifica quais os filmes mais similares com ele e retorna uma lista com os 5 mais próximos.

```
recommend('Iron Man')  
  
Iron Man 2  
Iron Man 3  
Avengers: Age of Ultron  
Captain America: Civil War  
The Avengers
```

Imagem 2 - Filmes recomendados pelo algoritmo ao entrar com ‘Iron Man’.

3. “Machine Learning, Data Science and Generative AI with Python - Recommender Systems”

3.1. User-based Collaborative Filtering

É uma técnica de recomendação que sugere itens a um usuário com base nas preferências de outros usuários semelhantes. O sistema analisa o comportamento e as avaliações do usuário para encontrar pessoas com gostos parecidos e, em seguida, recomenda itens que esses usuários semelhantes apreciaram, mas que o usuário em questão ainda não experimentou.

Não é um método muito interessante, visto que as pessoas podem mudar de preferência subitamente. Além disso, este método é muito suscetível a ataques onde alguns usuários podem, propositalmente, realizar um comportamento pouco comum para quebrar completamente as recomendações.

3.2. Item-based Collaborative Filtering

É uma técnica de recomendação que sugere itens a um usuário com base na similaridade entre itens. O sistema analisa quais objetos são semelhantes entre si com base nas avaliações de todos os usuários e, então, recomenda itens que são semelhantes aos que o usuário gostou. Dessa forma, se um item que o usuário apreciou tem outros semelhantes, esses são sugeridos ao usuário.

Essa abordagem é mais interessante, visto que as recomendações baseadas em itens são geralmente mais estáveis, pois a similaridade entre itens não muda com frequência, enquanto as preferências dos usuários podem variar.

O código da aula utilizou desse método para construir o sistema de recomendação. Com base nas avaliações dos outros usuários sobre o filme e considerando somente os itens com mais de 100 avaliações, foi realizado o cálculo da correlação entre os filmes, utilizando as próprias funções da biblioteca Pandas.

	size	mean	similarity
title			
Star Wars (1977)	584	4.359589	1.000000
Empire Strikes Back, The (1980)	368	4.206522	0.748353
Return of the Jedi (1983)	507	4.007890	0.672556
Raiders of the Lost Ark (1981)	420	4.252381	0.536117
Austin Powers: International Man of Mystery (1997)	130	3.246154	0.377433
Sting, The (1973)	241	4.058091	0.367538
Indiana Jones and the Last Crusade (1989)	331	3.930514	0.350107
Pinocchio (1940)	101	3.673267	0.347868
Frighteners, The (1996)	115	3.234783	0.332729
L.A. Confidential (1997)	297	4.161616	0.319065
Wag the Dog (1997)	137	3.510949	0.318645
Dumbo (1941)	123	3.495935	0.317656
Bridge on the River Kwai, The (1957)	165	4.175758	0.316580
Philadelphia Story, The (1940)	104	4.115385	0.314272
Miracle on 34th Street (1994)	101	3.722772	0.310921

Imagem 3 - Lista de recomendação para o filme “Star Wars (1977)”.

4. Conclusão

O estudo das abordagens para sistemas de recomendação demonstrou a complexidade e a importância de escolher métodos apropriados para atender às necessidades específicas dos usuários. A prática com a biblioteca Pandas e as técnicas de recomendação permitiu uma compreensão mais profunda de como diferentes métodos podem ser aplicados para personalizar a experiência do usuário.

A prática com esses métodos ilustra a necessidade de balancear entre a estabilidade das recomendações e a capacidade de adaptação às novas preferências dos usuários. Além disso, evidencia a importância de considerar as características específicas dos dados e dos usuários ao projetar e implementar sistemas de recomendação.