

Relatório sobre a atividade “26 - Prática: Modelos Generativos (III)”

Lucas Gabriel Arenhardt

1. Introdução

Neste módulo, foram explorados modelos generativos avançados, como Variational Auto-Encoders (VAEs) e Generative Adversarial Networks (GANs), que desempenham um papel fundamental na criação de dados sintéticos a partir de distribuições aprendidas. Esses modelos são amplamente utilizados em áreas como geração de imagens e textos, com aplicações práticas que vão desde o entretenimento até a pesquisa científica. Além disso, foi abordada a arquitetura Transformer, com foco no GPT, um modelo de destaque para geração de texto. O objetivo foi aprofundar o entendimento sobre o funcionamento, os desafios e as aplicações desses modelos em cenários reais.

2. Desenvolvimento

2.1. Variational Auto-Encoders (VAEs)

Os VAEs são uma classe de modelos generativos que utilizam a arquitetura de autoencoders com uma abordagem probabilística. O diferencial dos VAEs é a capacidade de gerar novas amostras ao aprender a distribuição dos dados de entrada, em vez de apenas reconstruí-los. A ideia central é que o modelo codifique os dados em um espaço latente contínuo, de onde pode-se amostrar novos pontos e gerar dados que seguem a mesma distribuição dos dados originais.

2.1.1. Reparametrização

A reparametrização é uma técnica crucial para o funcionamento dos VAEs, pois permite que o espaço latente seja amostrado de forma diferenciável. Para isso, o VAE gera dois vetores, a média e a variância, que são usados para amostrar os valores do espaço latente através da adição de ruído gaussiano. Essa estratégia é fundamental para o treinamento do modelo, pois garante que o processo de geração seja compatível com o algoritmo de backpropagation.

2.1.2. Divergência de Kullback-Leibler

Durante o treinamento, o VAE minimiza uma função de perda composta por dois termos: a perda de reconstrução, que mede a diferença entre os dados de entrada e

sua reconstrução pelo modelo, e a divergência de Kullback-Leibler (KL), que penaliza a diferença entre a distribuição latente aprendida e a distribuição gaussiana padrão. Esse balanço entre reconstrução e regularização é o que permite ao VAE gerar amostras coerentes com os dados de entrada.

2.1.3. Aplicações Práticas

Os VAEs têm aplicações em uma variedade de tarefas, como compressão de dados, redução de dimensionalidade e geração de amostras de dados sintéticos. Eles também são amplamente utilizados em problemas de geração de imagens, onde se deseja manter uma alta qualidade visual e coerência com a distribuição original. Outra aplicação prática inclui a colorização de imagens e o preenchimento de partes faltantes (inpainting).

2.2. Generative Adversarial Networks (GANs)

As GANs são compostas por dois modelos que competem entre si: um gerador, responsável por criar amostras que imitam os dados reais, e um discriminador, que tenta distinguir entre as amostras reais e as geradas. Esse processo adversarial é central para o sucesso das GANs, resultando em um gerador cada vez mais competente em criar amostras realistas. No entanto, o treinamento das GANs pode ser instável e requer um ajuste cuidadoso dos hiperparâmetros para alcançar bons resultados.

2.2.1. Estrutura e Desafios

A principal vantagem das GANs é sua capacidade de gerar amostras de alta qualidade e diversidade, como imagens realistas, vídeos e até músicas. No entanto, durante o treinamento, podem surgir problemas como o "Mode Collapse", no qual o gerador aprende a criar apenas um conjunto limitado de amostras, comprometendo a diversidade. Para mitigar esse problema, técnicas como a introdução de regularização ou o uso de variações da arquitetura padrão, como GANs condicionais e GANs baseados em Wasserstein, são frequentemente empregadas.

2.2.2. Aplicações Práticas

Os GANs têm aplicações práticas que vão desde a geração de imagens realistas até a criação de deepfakes e super-resolução de imagens. Em setores como o

de entretenimento e design, eles são usados para criar personagens virtuais, cenários e artefatos visuais realistas. Na pesquisa médica, GANs também são utilizados para gerar dados sintéticos, como exames médicos, que podem ser usados no treinamento de modelos de aprendizado de máquina, especialmente quando há escassez de dados reais.

2.3. Transformers e GPT

O Transformer é uma arquitetura que revolucionou o campo de processamento de linguagem natural (NLP) ao introduzir o mecanismo de self-attention, que permite que o modelo capture dependências de longo alcance em sequências de texto. Uma das implementações mais conhecidas dessa arquitetura é o GPT (Generative Pre-trained Transformer), que é amplamente utilizado para a geração de texto.

2.3.1. Implementação

O GPT é treinado de forma auto-regressiva, ou seja, ele gera um token de cada vez, condicionando cada novo token ao contexto anterior. Essa abordagem permite a criação de textos coerentes e contextualmente relevantes. A arquitetura Transformer do GPT inclui múltiplas camadas de self-attention e feedforward, permitindo que o modelo processe o texto de forma eficiente, capturando nuances e dependências complexas.

2.3.2. Aplicações

Os modelos GPT são aplicados em tarefas como geração de texto criativo, tradução automática, resumo de documentos e respostas a perguntas. O sucesso dos Transformers em NLP abriu portas para o desenvolvimento de modelos como o GPT-3, que podem realizar uma variedade de tarefas linguísticas com alta precisão e fluência.

3. Conclusão

A atividade demonstrou que VAEs e GANs são ferramentas poderosas para a geração de dados sintéticos, cada uma com suas particularidades. Os VAEs, com sua abordagem probabilística, são ideais para a geração de dados diversificados e coerentes com a distribuição original, enquanto os GANs se destacam na criação de amostras altamente realistas. A exploração de Transformers e GPT

também ilustrou a capacidade desses modelos de revolucionar o processamento de linguagem natural, gerando textos complexos e contextualmente adequados. O conhecimento adquirido sobre esses modelos abre novas possibilidades para aplicações em diversas áreas, como criação de imagens, produção de conteúdo e desenvolvimento de soluções em inteligência artificial.